

PROYECTO FINAL: MINERÍA DE DATOS (IEI-067)

Análisis Exploratorio, Modelado Predictivo y Despliegue Web con CRISP-DM

Duración: 3 semanas | Modalidad: Grupos (Obligatorio) | Entorno: Google Colab + Desarrollo Web (HTML/CSS/JS + Flask/FastAPI)

1. DESCRIPCIÓN GENERAL DEL PROYECTO

Objetivo: Aplicar el proceso CRISP-DM completo —incluyendo su fase final de Despliegue— a un problema real de negocio, utilizando un conjunto de datos de dominio público. El proyecto evalúa la capacidad del grupo para transformar datos crudos en información valiosa mediante técnicas de aprendizaje automático supervisado y no supervisado vistas en clase, y para llevar esos resultados a un producto funcional: una aplicación web que cualquier usuario, sin conocimientos técnicos, pueda usar para interactuar con el modelo.

Alcance: El proyecto no solo implica “hacer funcionar un código”. Se espera que el grupo comprenda el problema de negocio, limpie los datos rigurosamente, compare múltiples modelos, interprete los resultados en el contexto del negocio, y finalmente despliegue su modelo mediante una aplicación web full-stack (frontend + backend) que permita a un usuario final ingresar datos y obtener una predicción, un cluster o una recomendación basada en las reglas de asociación encontradas. Esta última etapa corresponde a la fase de Despliegue de CRISP-DM, frecuentemente omitida en proyectos académicos pero central en cualquier proyecto real de minería de datos.

2. SELECCIÓN DEL DATASET

Criterios obligatorios:

- **Fuente:** Kaggle (u otra fuente aprobada por el docente).
- **Tamaño:** Mínimo 500 registros y 5 atributos.
- **Variedad:** Debe contener variables numéricas y categóricas.
- **Restricciones:** No se permiten datasets de Iris, Titanic, Wine o aquellos ya usados en las clases prácticas.
- **Viabilidad analítica:** Debe permitir aplicar clasificación, clustering y reglas de asociación.
- **Viabilidad web:** Debe permitir construir una aplicación web con sentido para un usuario final (por ejemplo, que un vendedor prediga si un cliente comprará, o que un analista consulte a qué segmento pertenece un cliente nuevo).

Ejemplos sugeridos (Kaggle):

Dataset	Enfoque Principal
Mall Customer Segmentation	Clustering (K-Means) + Asociación
Students Performance	Clasificación (Árbol) + Clustering
Bank Marketing	Clasificación (Árbol) + Asociación
E-commerce Purchase Data	Asociación (Apriori) + Clasificación
Heart Disease UCI	Clasificación (Árbol) + Clustering

3. ENTREGABLES

Se deben entregar los siguientes cuatro artefactos, agrupados en un archivo ZIP con el nombre “GrupoX_Apellidos.zip”. Los enlaces de la aplicación web (repositorio y despliegue) no van dentro del ZIP: se incluyen como enlaces dentro del informe técnico.

1. Notebook (.ipynb)

Código ejecutable en Google Colab, con celdas de Markdown explicando cada paso y gráficos visibles.

2. Informe Técnico (.pdf)

Documento de 5-8 páginas estructurado según las fases de CRISP-DM, incluyendo ahora la sección de diseño y despliegue de la aplicación web (ver Sección 5).

3. Presentación (.pptx)

Archivo de apoyo para la exposición oral de 10 minutos, que debe incluir una demostración en vivo de la aplicación web (o el video de respaldo si el despliegue gratuito falla ese día).

4. Aplicación Web (full-stack)

- **Backend:** API desarrollada en Flask o FastAPI (Python) que carga el modelo entrenado (guardado con pickle o joblib) y expone al menos un endpoint de predicción/consulta.
- **Frontend:** Interfaz en HTML, CSS y JavaScript que consume la API y muestra los resultados de forma clara para un usuario no técnico.
- **Mockup:** Boceto o wireframe de las pantallas principales (Figma, Canva, o a mano escaneado/fotografiado), entregado ANTES de empezar a programar la aplicación (Semana 2).
- **Repositorio:** Enlace a un repositorio de GitHub con el código completo, historial de commits del equipo, y un README con instrucciones para ejecutar la app localmente.
- **Despliegue:** Enlace a la aplicación funcionando en línea (Render, Railway, PythonAnywhere u otro servicio gratuito). Si el servicio gratuito falla el día de la entrega, debe adjuntarse un video de respaldo (máx. 2 minutos) mostrando la app funcionando localmente.

4. CRONOGRAMA DE TRABAJO (3 SEMANAS)

Se establece un cronograma estricto con entregables parciales para garantizar el avance constante. Las dos semanas adicionales respecto al proyecto original están dedicadas al diseño y desarrollo de la aplicación web.

Semana 1: Comprensión y Preparación

- **Viernes:** Formación de grupos y selección del dataset.
- **Viernes:** Entrega Parcial 1 (Fases 1 y 2 de CRISP-DM: Negocio y Datos).

Semana 2: Modelado

Viernes 2: se presenta prototipo de la aplicación

Semana 3: Presentación

Viernes 9: se presenta el proyecto grupal

5. ESTRUCTURA DEL INFORME (GUÍA DETALLADA)

El informe debe seguir estrictamente este esquema. La nota se asigna proporcionalmente a la calidad de cada sección.

5.1 Comprensión del Negocio (10%)

Preguntas que debe responder:

¿Cuál es el contexto del problema? ¿Qué intenta resolver el negocio con estos datos? ¿Cómo se medirá el éxito del proyecto?

5.2 Comprensión de los Datos (10%)

Preguntas que debe responder:

¿Cuántos registros y columnas tiene el dataset? ¿Qué tipo de datos hay (numéricos, categóricos)? ¿Cuál es la variable objetivo (Class) y cuáles son las predictoras (Meta)? Muestre estadísticas descriptivas (.describe()) y gráficos de distribución.

5.3 Preparación de los Datos (15%)

Preguntas que debe responder:

¿Cómo manejaron los valores nulos? ¿Detectaron outliers con el método IQR y qué decisión tomaron? ¿Codificaron las variables categóricas (LabelEncoder/OneHotEncoder)? ¿Escararon los datos si era necesario? ¿Cómo dividieron los datos en entrenamiento y prueba?

5.4 Modelado (25%)

Deben implementar y documentar TRES técnicas:

- **A) Reglas de Asociación (Apriori):** Usen la librería mlxtend. Reporten al menos 3 reglas con sus métricas de Soporte, Confianza y Lift. Interpreten qué significan esas reglas para el negocio.
- **B) Clustering (K-Means):** Usen scikit-learn. Justifiquen la elección de K (método del codo o silueta). Describan las características de cada grupo encontrado.
- **C) Clasificación (Árbol de Decisión):** Usen DecisionTreeClassifier. Prueben diferentes valores de max_depth para evitar sobreajuste. Muestren el árbol gráfico y la matriz de confusión.

5.5 Evaluación (8%)

Comparen los modelos. ¿Cuál tuvo mejor Accuracy? ¿Por qué? ¿Qué limitaciones encontraron en el dataset o en las técnicas?

5.6 Conclusiones (7%)

Resuman los hallazgos más importantes. Den recomendaciones accionables (ej. “Se recomienda hacer campaña de marketing al Cluster 2 porque...”). ¿Qué harían diferente si tuvieran más tiempo o mejores datos?

5.7 Mockup, Desarrollo y Despliegue de la Aplicación Web (10% + 15%)

Preguntas que debe responder:

¿Qué problema resuelve la aplicación para el usuario final? Incluya el mockup entregado en la Semana 2 y explique cómo se relaciona con la versión final: ¿qué cambió en el camino y por qué? ¿Qué arquitectura utilizaron (diagrama simple de cómo el frontend se comunica con el backend, y este con el modelo)? ¿Qué tecnologías eligieron para el backend y el frontend, y por qué? ¿Qué dificultades enfrentaron al desplegar la app y cómo las resolvieron? Incluya capturas de pantalla del mockup y de la aplicación final funcionando, y los enlaces al repositorio y al despliegue.

6. RÚBRICA DE EVALUACIÓN (100 PUNTOS)

La siguiente rúbrica detalla los criterios de evaluación. Se espera un nivel de calidad profesional.

A. Comprensión del Negocio (10 pts)

Nivel	Descripción
Excelente (9-10)	Contexto claro, objetivo específico y medible, valor de negocio bien argumentado.
Bueno (6-8)	Contexto descrito, objetivo presente pero genérico.
Insuficiente (0-5)	Contexto vago o ausente, sin valor de negocio.

B. Exploración y Comprensión de Datos (10 pts)

Nivel	Descripción
Excelente (9-10)	Descripción completa, estadísticas detalladas, visualizaciones relevantes, identificación clara de Class/Meta.
Bueno (6-8)	Descripción adecuada, estadísticas presentes, algunas visualizaciones.
Insuficiente (0-5)	Sin descripción ni estadísticas.

C. Preparación de Datos (15 pts)

Nivel	Descripción
Excelente (13-15)	Trata nulos, detecta outliers con IQR, codifica correctamente, escala si aplica, divide train/test correctamente.
Bueno (9-12)	Trata nulos, detecta outliers (sin IQR), codifica, divide train/test.
Insuficiente (0-8)	No prepara datos o preparación incorrecta.

D. Modelado (25 pts)

Nivel	Descripción
Excelente (22-25)	Apriori: interpretación profunda. K-Means: justifica K y describe clusters. Árbol: experimenta con parámetros y visualiza.
Bueno (16-21)	Apriori: reglas presentes. K-Means: aplica con K fijo. Árbol: entrena y evalúa.
Insuficiente (0-15)	Falta uno o más modelos, o están mal aplicados.

E. Evaluación y Conclusiones (15 pts)

Nivel	Descripción
Excelente (13-15)	Comparación objetiva, justificación del mejor modelo, recomendaciones accionables para el negocio.
Bueno (9-12)	Compara modelos, recomendaciones generales.
Insuficiente (0-8)	Sin comparación ni conclusiones.

F. Mockup / Prototipo de la Aplicación (10 pts)

Evalúa específicamente el mockup entregado en la Semana 2, ANTES de programar la aplicación

Nivel	Descripción
Excelente (9-10)	Mockup entregado a tiempo, muestra con claridad todas las pantallas principales y el flujo de uso completo (qué información pide al usuario y qué le devuelve la app), incluye el diagrama de arquitectura, y es coherente con la funcionalidad de la app final.
Bueno (6-8)	Mockup entregado, pero incompleto (falta alguna pantalla, el diagrama de arquitectura, o parte del flujo de uso) o con diferencias relevantes respecto a la app final.
Insuficiente (0-5)	Mockup ausente, entregado fuera de plazo sin justificación, o no representa el flujo real de la aplicación.

G. Desarrollo y Despliegue de la Aplicación Web (15 pts)

Evalúa la aplicación ya construida: si implementa fielmente lo definido en el mockup y si quedó funcionando en línea.

Nivel	Descripción
Excelente (13-15)	Arquitectura frontend-backend bien implementada y documentada; API funcional que sirve el modelo correctamente; frontend usable, ordenado y con buen manejo de errores; app desplegada, accesible públicamente y estable; repositorio con historial de commits que evidencia trabajo de todo el equipo.
Bueno (9-12)	Backend y frontend funcionan pero con errores menores o diseño básico; despliegue funcional aunque con fallas ocasionales; commits concentrados en pocos integrantes.
Insuficiente (0-8)	Aplicación no funcional, o no desplegada ni respaldada con video, o backend y frontend no están correctamente conectados.

7. RESTRICCIONES IMPORTANTES

Prohibido: Usar modelos avanzados no vistos en clase (Random Forest, XGBoost, Redes Neuronales) — el objetivo es dominar lo básico. Tampoco se permite usar plataformas de generación automática de aplicaciones sin programar (no-code/low-code, ej. Bubble, Glide): el objetivo es que el grupo programe el backend y el frontend.

Obligatorio: Cada línea de código debe tener un comentario. Los gráficos deben tener título y etiquetas. No se aceptan resultados sin interpretación. El backend debe estar desarrollado en Flask o FastAPI, y el frontend en HTML/CSS/JavaScript (se permite un framework liviano de estilos como Bootstrap, pero no frameworks completos de frontend como React o Vue, salvo autorización del docente). La aplicación debe manejar los errores de entrada del usuario de forma amigable, sin mostrar errores de Python en pantalla.

Uso de IA: Se permite usar IA para entender conceptos o depurar errores, tanto en el modelo como en el código de la aplicación web, pero el resultado final debe ser propio y comprensible para todo el grupo. Copiar y pegar sin entender es fraude académico.

8. PREGUNTAS FRECUENTES

P: ¿Puedo trabajar solo?

R: No. El trabajo es obligatorio en grupos. No se aceptan entregas individuales.

P: ¿Puedo usar otro dataset que no sea de Kaggle?

R: Sí, siempre que cumpla los requisitos y sea aprobado por el profesor.

P: ¿Puedo usar Random Forest o XGBoost?

R: No. El objetivo es demostrar dominio de las técnicas vistas en clase.

P: ¿Qué pasa si mi dataset no permite reglas de asociación?

R: Debes elegir un dataset que tenga variables transaccionales o categóricas. Consulta con el profesor.

P: ¿Qué tecnologías puedo usar para el backend de la aplicación?

R: Flask o FastAPI (Python), conectado al modelo ya entrenado y guardado con pickle o joblib. No se permiten plataformas no-code.

P: ¿Dónde puedo desplegar la aplicación gratis?

R: Render, Railway y PythonAnywhere son opciones gratuitas recomendadas para el backend. Si separan el frontend, pueden usar GitHub Pages o Vercel; también pueden servir el frontend directamente desde el mismo backend Flask/FastAPI.

P: ¿Qué pasa si el despliegue gratuito se cae el día de la exposición?

R: Además del enlace en línea, deben entregar un video de respaldo (máx. 2 minutos) mostrando la aplicación funcionando localmente. Si el enlace falla ese día, se evaluará con ese video.

P: ¿El mockup tiene que estar hecho en una herramienta profesional como Figma?

R: No es obligatorio. Puede ser un boceto digital en cualquier herramienta, o incluso a mano y escaneado o fotografiado, siempre que muestre con claridad las pantallas principales y el flujo de uso antes de programar.

Profesores: Florentino Vargas y Rosa Rao

Asignatura: Minería de Datos (IEI-067)

Institución: Santo Tomás